

PREDIKSI HARGA KOMODITAS PANGAN STRATEGIS BERBASIS MACHINE LEARNING UNTUK DETEKSI DINI KETAHANAN PANGAN

Lidia Natasyah Marpaung^{1*}; Melinza Nabila²; Aisyah Musfirah³; Ahmad Risqi⁴; Benget Sidabutar⁵

Data Science¹

Institut Teknologi Sumatera, Lampung Selatan, Indonesia¹

<https://www.itera.ac.id>¹

lidia.123450015@student.itera.ac.id^{1*}

melin.123450122@student.itera.ac.id²

aisyah.123450084@student.itera.ac.id³

ahmad.122450138@student.itera.ac.id⁴

benget.123450047@student.itera.ac.id⁵

(*) Corresponding Author

(Responsible for the Quality of Paper Content)



The creation is distributed under the Creative Commons Attribution-NonCommercial 4.0 International License.

Abstract—Food security is a critical pillar of national development, yet price volatility across strategic commodities continually threatens economic stability and purchasing power. This study addresses the lack of large-scale predictive systems focusing on food price stability by developing a distributed big data pipeline based on the Medallion Lakehouse architecture using MinIO and PySpark. The framework integrates multivariate datasets containing 19,446 records from three heterogeneous sources: historical food prices from Bapanas, climate data from Open-Meteo, and macroeconomic exchange rates from Yahoo Finance across 38 Indonesian provinces from 2021 to 2026. Data analytics and feature engineering were executed using PySpark MLlib, applying StringIndexer and One-Hot Encoding before training Random Forest Regressor and Decision Tree Regressor models under an 80:20 data split. The computational evaluation proved that in-memory caching significantly optimizes performance, reducing execution time from 8.48 seconds to 3.62 seconds. For predictive analytics, both models exceeded the baseline target of 85%. The Decision Tree model achieved the best performance with an R^2 score of 88.65% and a Root Mean Square Error (RMSE) of 11,319.87 in just 1.07 seconds, slightly outperforming Random Forest. Feature importance analysis revealed that commodity identity, particularly beef at 73%, heavily governed the predictions due to large absolute nominal gaps. This system provides a robust predictive foundation to support national early warning systems for food security

Keywords: decision tree, food security, lakehouse, machine learning, pyspark.

Intisari— Ketahanan pangan merupakan pilar utama pembangunan nasional, namun volatilitas harga komoditas strategis terus mengancam stabilitas ekonomi dan daya beli masyarakat. Penelitian ini mengatasi keterbatasan sistem analitik berskala besar yang berfokus pada stabilitas harga dengan membangun pipeline data masif berbasis arsitektur Medallion Lakehouse menggunakan MinIO dan PySpark. Sistem ini mengintegrasikan 19.446 baris data terpadu dari tiga sumber heterogen, meliputi harga pangan Bapanas, cuaca harian Open-Meteo, dan kurs Yahoo Finance di 38 provinsi Indonesia periode 2021 sampai 2026. Prapemrosesan dan rekayasa fitur dilakukan melalui PySpark MLlib dengan StringIndexer dan OneHotEncoder, lalu dievaluasi menggunakan algoritma Random Forest Regressor dan Decision Tree Regressor dengan rasio data 80:20. Hasil pengujian komputasi membuktikan bahwa mekanisme in-memory caching berhasil memangkas waktu pemrosesan secara signifikan dari 8,48 detik menjadi 3,62 detik. Dari sisi analitik prediktif, kedua model berhasil melampaui target akurasi awal sebesar 85%. Algoritma Decision Tree Regressor mencatatkan performa terbaik dengan nilai R^2 sebesar 88,65% dan RMSE sebesar 11.319,87 dalam waktu pelatihan yang instan yaitu 1,07 detik. Analisis feature importance menunjukkan bahwa identitas komoditas, khususnya Daging Sapi Murni dengan kontribusi 73%, mengendalikan prediksi secara mutlak

akibat perbedaan nominal harga absolut yang ekstrem. Sistem ini menyediakan instrumen prediktif yang kuat untuk mendukung sistem deteksi dini ketahanan pangan nasional.

Kata Kunci: decision tree, ketahanan pangan, lakehouse, machine learning, pyspark.

INTRODUCTION

Pencapaian ketahanan pangan merupakan agenda krusial dalam *Sustainable Development Goals* (SDG) tujuan kedua terkait pengentasan kelaparan (*Zero Hunger*). Ketahanan pangan sendiri merupakan pilar utama dalam pembangunan nasional karena berdampak langsung pada kestabilan ekonomi dan kesejahteraan masyarakat. Upaya menjaga stabilitas ini sangat krusial, terutama pada periode dimana volatilitas harga dapat mengancam daya beli rumah tangga dan memicu guncangan sosial ekonomi [1]. Tinjauan sistematis yang dilakukan oleh Ammar dkk. [2] terhadap lebih dari 130 artikel menemukan bahwa mayoritas model analitik yang ada saat ini hanya berfokus pada dimensi ketersediaan (*availability*) pangan dan mengabaikan dimensi stabilitas (*stability*) serta pemanfaatan (*utilization*). Kondisi ini menciptakan kesenjangan besar dalam kerangka analitik ketahanan pangan secara global. Kesenjangan ini berdampak nyata pada negara berkembang seperti Indonesia, di mana fluktuasi harga komoditas strategis yang tidak terkendali dapat memicu inflasi dan membatasi akses masyarakat terhadap pangan yang layak [2].

Sebagai gambaran nyata, dampak inflasi pangan di Indonesia terasa sangat merusak pada periode akhir tahun 2023 hingga awal tahun 2024. Pada rentang waktu tersebut, fenomena anomali iklim El Nino memicu gangguan produksi pertanian, khususnya pada komoditas hortikultura, secara masif di wilayah sentra produksi seperti Pulau Jawa dan Sumatera [1]. Gangguan rantai pasok ini menyebabkan lonjakan harga yang ekstrem pada berbagai komoditas strategis seperti beras dan aneka jenis cabai. Akibatnya, tingkat inflasi nasional terdorong naik secara tajam melebihi rata-rata tahunan. Bagi kelompok rumah tangga berpendapatan rendah yang mengalokasikan sebagian besar pengeluaran mereka untuk konsumsi makanan, lonjakan harga belasan persen ini secara langsung menggerus daya beli riil mereka hingga menciptakan risiko ketidakamanan pangan serta ketimpangan gizi yang serius [1].

Pergerakan harga pangan tidak terjadi secara tunggal, melainkan dipengaruhi oleh interaksi

kompleks dari kondisi cuaca (seperti curah hujan dan suhu) serta faktor makroekonomi seperti nilai tukar mata uang. Mengelola data lintas sektoral dengan volume dan keragaman tinggi membutuhkan infrastruktur analitik yang tangguh. Roukha dkk. [3] menegaskan bahwa pemrosesan data agrikultur bervolume tinggi dari berbagai sumber digital tidak dapat dilakukan secara terpusat. Implementasi arsitektur komputasi terdistribusi mutlak diperlukan agar sistem tidak mengalami kegagalan saat menangani data dengan resolusi tinggi. Dalam skenario ini, pemanfaatan ekosistem Big Data seperti PySpark yang dikombinasikan dengan strategi in-memory caching terbukti secara akademis mampu mengoptimalkan kinerja sistem dan memangkas waktu eksekusi komputasi berskala masif secara signifikan [4].

Untuk mengelola aliran data masif tersebut, pemilihan arsitektur penyimpanan menjadi sangat penting. Secara tradisional, sistem analitik sangat bergantung pada arsitektur Data Warehouse. Sistem konvensional ini mensyaratkan data untuk dibersihkan dan diubah ke dalam skema baku sebelum disimpan (*schema-on-write*). Proses ini cenderung kaku dan memakan waktu lama jika dihadapkan pada data yang beragam serta berkecepatan tinggi seperti log cuaca atau pergerakan kurs harian. Sebagai alternatif, muncul konsep Data Lake yang menawarkan ruang penyimpanan data mentah apa adanya dalam skala masif dengan biaya murah. Namun, Data Lake sering kali bermasalah dengan kualitas data yang buruk dan sulit diakses, atau kerap disebut sebagai fenomena rawa data (*data swamp*). Beranjak dari kelemahan kedua sistem tersebut, pendekatan arsitektur Lakehouse kini hadir sebagai solusi modern [3], [4]. Arsitektur ini menjembatani fleksibilitas penyimpanan tanpa batas ala Data Lake dengan keandalan tata kelola serta kecepatan analitik ala Data Warehouse, sehingga semakin banyak diadopsi untuk mengelola kompleksitas data agrikultur terpadu.

Di tahap pemrosesan akhir, teknologi Machine Learning sangat krusial untuk memetakan pola multivariat dari data historis harga, cuaca, dan kurs demi menghasilkan prediksi harga masa depan secara optimal. Penggunaan algoritma berbasis pohon keputusan atau ansambel sangat diminati karena kemampuannya dalam mengekstraksi tingkat kepentingan fitur (*feature importance*), yang

secara efektif membantu mengidentifikasi variabel paling dominan di balik fluktuasi harga pasar [5]. Aditya dkk. [6] mengkomparasi algoritma Random Forest, Decision Tree, dan K-Nearest Neighbors untuk memprediksi produksi padi berdasarkan faktor iklim dan luas lahan, di mana Random Forest terbukti menghasilkan stabilitas prediksi tertinggi dengan nilai persentase R^2 sebesar 85,83%. Namun, literatur lain yang membandingkan kedua algoritma tersebut menunjukkan bahwa pada tipe struktur data tertentu, model Decision Tree mampu menyamai keakuratan Random Forest sekaligus memberikan keunggulan waktu pelatihan yang jauh lebih cepat dan ringan [7].

Sejalan dengan itu, Muchtar dan Afiyati [8] membuktikan bahwa Random Forest mampu memprediksi harga beras premium di Jawa Barat dengan akurasi R^2 0,97, mengungguli Linear Regression yang hanya mencapai R^2 0,89. Dalam konteks prediksi harga pangan multi-komoditas, Fadillah dkk. [9] menerapkan metode Fuzzy Time Series berbasis rata-rata untuk memprediksi harga pangan di Provinsi Aceh dan memperoleh nilai MAPE terbaik sebesar 0,49% untuk beras kualitas super. Harjanto dkk. [10] juga membandingkan Decision Tree, Random Forest, dan LSTM pada komoditas ekspor Indonesia, dan menemukan bahwa LSTM menghasilkan akurasi tertinggi, meskipun Decision Tree dan Random Forest tetap kompetitif untuk data berdimensi lebih sederhana.

Selain perdebatan pemilihan algoritma, metodologi pada studi Aditya dkk. [6] memiliki kelemahan mendasar pada cakupan datanya karena hanya mencakup agregasi dari delapan provinsi di Sumatera dengan resolusi tahunan. Skala tersebut tidak mencerminkan variabilitas iklim nasional secara riil dan tidak dapat merepresentasikan dinamika harga yang berfluktuasi setiap bulan. Selain itu, kajian oleh Saragih dan Wibowo [11] menunjukkan bahwa pendekatan machine learning untuk prediksi Indeks Ketahanan Pangan Indonesia masih memerlukan integrasi data multisumber berskala nasional agar hasilnya lebih representatif. Oleh karena itu, penelitian ini bertujuan membangun sistem pengolahan data masif berbasis Lakehouse menggunakan MinIO dan PySpark yang mengintegrasikan data harga 27 komoditas, cuaca, dan kurs pada resolusi bulanan mencakup 38 provinsi di Indonesia. Lebih lanjut, algoritma Random Forest Regressor dan Decision Tree Regressor

diimplementasikan dan dikomparasikan performanya untuk memprediksi stabilitas harga komoditas pangan strategis guna mendukung sistem deteksi dini ketahanan pangan nasional.

MATERIALS AND METHODS

Penelitian ini menerapkan pendekatan kuantitatif dengan membangun sistem pipeline data masif berbasis arsitektur *Lakehouse* terdistribusi yang diintegrasikan dengan algoritma *machine learning* untuk memprediksi harga komoditas pangan. Seluruh sistem dibangun di atas ekosistem Apache Spark (PySpark) yang dijalankan di dalam kontainer Docker guna memastikan skalabilitas dan portabilitas lingkungan komputasi. MinIO digunakan sebagai media penyimpanan objek (*Object Storage*) yang menampung data pada setiap tahapan arsitektur Medallion, yakni lapisan *Bronze*, *Silver*, dan *Gold*.

Untuk memastikan keandalan eksperimen, komputasi dieksekusi pada lingkungan perangkat keras dengan alokasi memori utama (RAM) sebesar 16 GB dan unit pemrosesan sentral (CPU) 8-core. Lingkungan pengembangan ini diorkestrasi sepenuhnya menggunakan utilitas Docker Compose untuk membangun dua layanan utama secara berdampingan, yaitu peladen MinIO dan ruang kerja komputasi PySpark. Proses instalasi PySpark di dalam kontainer dilakukan melalui beberapa tahapan berurutan, dimulai dengan penyiapan sistem operasi dasar, pemasangan Java Development Kit (JDK) sebagai prasyarat mutlak berjalannya mesin virtual Java (JVM) untuk Spark, dan diakhiri dengan instalasi pustaka PySpark melalui pengelola paket Python. Sementara itu, peladen MinIO dikonfigurasi secara lokal dengan port yang terisolasi untuk meniru perilaku layanan penyimpanan objek awan secara persis. Pada peladen MinIO tersebut, tiga keranjang (*bucket*) terpisah dibuat secara spesifik untuk mengamankan tata kelola data pada setiap tahap arsitektur Medallion.

Data yang digunakan mencakup periode Januari 2021 hingga Januari 2026 dan bersumber dari tiga domain yang berbeda. Sumber pertama adalah data harga 27 komoditas pangan strategis bulanan di tingkat provinsi yang diperoleh dari portal Open Data Badan Pangan Nasional (Bapanas). Sumber kedua adalah data cuaca historis harian berupa suhu rata-rata dan curah hujan yang diekstraksi secara otomatis melalui API Open-Meteo untuk koordinat ibu kota dari 38 provinsi di Indonesia. Sumber ketiga adalah data pergerakan kurs

penutupan harian USD terhadap Rupiah yang diperoleh melalui API Yahoo Finance pada rentang waktu yang sama. Sebelum proses agregasi, total data mentah yang berhasil diekstraksi terdiri dari 55.711 baris data cuaca harian, 36.349 baris data harga pangan bulanan, dan 1.322 baris data kurs harian. Pada tahap awal, seluruh data mentah dari ketiga sumber tersebut diekstraksi dan langsung disimpan ke lapisan *Bronze* di MinIO dalam format aslinya tanpa modifikasi apa pun.

Proses integrasi dan prapemrosesan data dilakukan pada lapisan *Silver* menggunakan PySpark. Data cuaca dan kurs yang awalnya beresolusi harian terlebih dahulu diagregasi menjadi nilai rata-rata bulanan menggunakan operasi *groupBy* berdasarkan dimensi tahun, bulan, dan nama provinsi. Selanjutnya, ketiga sumber data tersebut digabungkan menggunakan operasi *Left Join* berdasarkan kunci yang sama. Nilai kosong (*missing value*) yang muncul akibat ketidakcocokan penggabungan dibersihkan menggunakan metode penghapusan baris (*dropna*). Data terpadu yang telah bersih kemudian dikonversi dan disimpan ke dalam format Parquet untuk mengoptimalkan kecepatan pembacaan pada tahap komputasi berikutnya.

Tahap rekayasa fitur (*Feature Engineering*) dan pemodelan dieksekusi pada lapisan *Gold*. Melalui pustaka PySpark MLlib, variabel kategorikal berupa nama provinsi, jenis komoditas, dan bulan ditransformasi menjadi representasi numerik menggunakan kombinasi *StringIndexer* dan *OneHotEncoder*. Variabel bulan diperlakukan sebagai fitur kategorikal, bukan numerik, untuk menangkap pola musiman yang bersifat siklikal dan tidak linier. Seluruh variabel prediktor yang dihasilkan kemudian disatukan ke dalam satu vektor fitur menggunakan *VectorAssembler*. Dataset dibagi dengan rasio 80:20 untuk pelatihan (*training*) dan pengujian (*testing*). Algoritma *Random Forest Regressor* ditetapkan sebagai model utama, dengan *Decision Tree Regressor* sebagai model pembanding. Kinerja kedua model dievaluasi menggunakan dua metrik: Koefisien Determinasi (R^2) untuk mengukur proporsi variansi yang mampu dijelaskan model, dan *Root Mean Square Error* (RMSE) untuk mengukur besaran rata-rata kesalahan prediksi dalam satuan rupiah. Selain evaluasi akurasi prediktif, efisiensi arsitektur komputasi juga diuji dengan membandingkan durasi pelatihan model

menggunakan mekanisme *In-Memory Caching* terhadap pembacaan data iteratif dari disk.

RESULTS AND DISCUSSION

Proses ETL pada pipeline *Lakehouse* berhasil mengintegrasikan 55.711 baris data cuaca harian, 36.349 baris data harga pangan, dan 1.322 baris data kurs menjadi 19.446 baris dataset terpadu yang bersih di lapisan *Gold*, siap diproses ke tahap pemodelan. Pengujian efisiensi komputasi pada ekosistem PySpark membuktikan keunggulan mekanisme *In-Memory Caching*. Pemrosesan model *Random Forest* yang dilakukan dengan pembacaan data iteratif dari disk (tanpa *cache*) membutuhkan durasi 8,48 detik. Sebaliknya, ketika data ditahan di dalam memori utama (*cache*), waktu komputasi terpankas menjadi 3,62 detik dimana peningkatan efisiensi lebih dari dua kali lipat. Mekanisme ini secara efektif mengeliminasi operasi *Input/Output* (I/O) pada disk yang sering kali menjadi leher botol (*bottleneck*) dalam pemrosesan data berskala masif. Hasil ini mengonfirmasi bahwa mekanisme *in-memory processing* pada PySpark sangat krusial untuk menekan latensi ketika sistem menangani beban data pertanian secara berulang, sehingga sangat relevan diimplementasikan pada sistem pemantauan nasional yang membutuhkan pembaruan analitik secara cepat.

Sebelum melangkah pada evaluasi performa model prediktif, penting untuk memahami karakteristik distribusi data harga dari beberapa komoditas utama yang menjadi sorotan. Tabel 1 menyajikan statistik deskriptif dasar yang mencakup nilai rata-rata, nilai tertinggi, serta nilai terendah dari tiga komoditas representatif yang memiliki rentang nilai berbeda.

Tabel 1. Distribusi Statistik Harga Komoditas Utama (Rupiah)

Komoditas	Nilai Terendah	Nilai Tertinggi	Rata-rata
Daging Sapi Murni	104.500	162.758	135.562
Cabai Rawit Merah	14.294	127.906	59.885
Beras Premium	10.490	28.750	14.238

Distribusi statistik pada Tabel 1 memperlihatkan rentang harga (*variance*) yang sangat timpang antar-komoditas. Daging sapi murni memiliki basis harga nominal yang sangat tinggi dan menyentuh ratusan ribu rupiah. Cabai rawit merah

menampilkan fluktuasi yang ekstrem di mana harga tertingginya bisa mencapai hampir sembilan kali lipat dari harga terendahnya, merepresentasikan tingkat kerentanan pasokan yang sangat tinggi di pasar. Sebaliknya, komoditas beras memiliki rentang pergerakan harga yang lebih sempit dan basis nominal yang jauh lebih rendah. Tingginya disparitas harga absolut antar-komoditas ini tidak hanya menjadi tantangan bagi daya beli masyarakat, tetapi juga memberikan tantangan teknis tersendiri bagi algoritma pembelajaran mesin dalam memetakan pola distribusi yang tidak seragam.

Evaluasi performa analitik kemudian difokuskan pada komparasi metrik Koefisien Determinasi (R^2) dan *Root Mean Square Error* (RMSE) antara model *Decision Tree* dan *Random Forest*. Rangkuman hasil pengujian kedua model disajikan pada Tabel 2.


Tabel 2. Hasil Evaluasi Performa Algoritma Prediksi

Algoritma	Waktu Pelatihan	RMSE	Koefisien Determinasi (R^2)
<i>Decision Tree</i>	1,07 Detik	11.319,87	88,65 %
<i>Random Forest</i>	3,62 Detik	11.522,36	88,24 %

Hasil komparasi menghasilkan temuan yang menarik: model *Decision Tree Regressor* berhasil

mengungguli *Random Forest* dengan selisih R^2 sebesar 0,41%, sekaligus mencatatkan RMSE yang lebih rendah (11.319,87 vs 11.522,36) dan waktu pelatihan yang jauh lebih singkat (1,07 detik vs 3,62 detik). Capaian ini melampaui target akurasi $R^2 \geq 85\%$ yang ditetapkan di awal. Keunggulan *Decision Tree* atas *Random Forest* pada penelitian ini kemungkinan disebabkan oleh karakteristik dataset yang didominasi oleh satu fitur dengan rentang nilai ekstrem yaitu kondisi di mana pohon tunggal sudah cukup efektif menemukan *decision split* optimal tanpa memerlukan mekanisme *ensemble*. Temuan ini sejalan dengan argumen bahwa keunggulan *Random Forest* umumnya lebih terlihat pada dataset dengan distribusi fitur yang lebih merata dan kompleks [6].

Sebagai catatan analitis tambahan, meskipun nilai R^2 terlihat sangat memuaskan, metrik RMSE sebesar 11.319,87 rupiah perlu diinterpretasikan secara kritis. Untuk komoditas dengan basis harga tinggi seperti daging sapi yang rata-ratanya berada di atas 135.000 rupiah, kesalahan prediksi sebesar sebelas ribu rupiah merupakan deviasi *error* yang sangat kecil dan dapat ditoleransi oleh sistem. Namun, bagi komoditas dengan basis harga rendah seperti beras, angka kesalahan absolut 11.319 rupiah tersebut menjadi sangat tidak proporsional karena hampir menyamai harga asli komoditas itu sendiri. Hal ini kembali menegaskan bahwa penggabungan seluruh komoditas ke dalam satu pemodelan spasial universal cenderung lebih menguntungkan komoditas bernilai tinggi.



Gambar 1. Perbandingan Harga Aktual dan Prediksi (100 Sampel Acak)


Pada Gambar 1, garis prediksi (merah) secara umum mengikuti pola pergerakan harga aktual (biru) di sepanjang rentang sampel. Model

berhasil menangkap transisi antar-komoditas yang membentuk lonjakan nilai ekstrem, yang tercermin dari pola naik-turun yang konsisten

antara kedua garis. Namun demikian, terdapat beberapa titik di mana garis prediksi tidak sepenuhnya mengikuti harga aktual, misalnya pada beberapa puncak lonjakan di indeks 25 hingga 35 dan 80 hingga 90, yang merepresentasikan batas generalisasi model pada sampel dengan variabilitas tinggi. Kegagalan model dalam menangkap titik puncak ekstrem ini sangat wajar terjadi pada data deret waktu ekonomi agrikultur. Hal ini sering kali dipicu oleh adanya faktor-faktor kejutan eksternal yang tidak tertangkap oleh fitur model, seperti kepanikan

pasar menjelang hari raya keagamaan atau kelangkaan pasokan mendadak akibat blokade jalur distribusi. Secara keseluruhan, pola visual ini mengindikasikan bahwa model telah menangkap struktur dasar data secara memadai tanpa indikasi *overfitting* yang signifikan.

Untuk memahami logika keputusan model secara lebih mendalam, dilakukan ekstraksi *Feature Importance* sebagaimana ditampilkan pada Gambar 2.



Gambar 2. Ekstraksi Tingkat Kepentingan Fitur (*Feature Importance*)

Gambar 2 mengungkap bahwa seluruh 10 fitur dengan kontribusi tertinggi merupakan representasi *one-hot* dari variabel jenis komoditas, dengan Daging Sapi Murni mendominasi pada tingkat kepentingan sekitar 0,73, jauh melampaui Cabai Rawit Merah di posisi kedua yang hanya sekitar 0,06. Tidak ada satu pun variabel cuaca maupun kurs yang masuk dalam jajaran 10 fitur terpenting. Hal ini secara teknis dijelaskan oleh perbedaan nominal absolut antar-komoditas. Harga daging sapi yang berada pada kisaran ratusan ribu rupiah menghasilkan ragam target yang sangat besar sehingga algoritma secara otomatis menjadikan identitas komoditas tersebut sebagai pemecah keputusan utama untuk meminimalkan RMSE keseluruhan.

Sementara itu, komoditas seperti cabai rawit merah atau beras menempati urutan yang jauh lebih bawah dalam grafik tingkat kepentingan fitur tersebut. Meskipun harga cabai rawit merah sering kali mengalami persentase lonjakan yang

drastis akibat gangguan musim hujan, rentang kenaikan absolut harganya dalam wujud rupiah masih jauh lebih kecil dibandingkan selisih harga daging sapi terhadap komoditas lain. Lebih jauh lagi pada komoditas beras, intervensi operasi pasar dari pemerintah membuat pergerakan harganya relatif lebih lambat dan terkendali. Karena algoritma pohon keputusan bekerja dengan tujuan utama menekan total kesalahan prediktif dalam satuan rupiah absolut, mesin secara alamiah akan mengabaikan dinamika pada cabai atau beras. Mesin akan terus memfokuskan percabangan utamanya pada daging sapi yang secara nominal memberikan sumbangan angka kesalahan mutlak terbesar jika salah diprediksi. Konsekuensi metodologis dari fenomena ini adalah model menjadi bias dan lebih banyak belajar dari sekadar perbedaan skala harga antar-komoditas dibandingkan mengekstraksi korelasi dari sinyal iklim dan makroekonomi yang menjadi motivasi awal penelitian. Untuk penelitian selanjutnya, sangat direkomendasikan untuk

melakukan normalisasi harga per komoditas sebelum pemodelan, atau membangun model prediksi yang terpisah secara independen untuk setiap komoditas. Pendekatan model terpisah tersebut diproyeksikan tidak hanya akan mendongkrak sensitivitas algoritma terhadap variabel eksternal seperti curah hujan dan fluktuasi kurs, tetapi juga memungkinkan penyesuaian parameter yang jauh lebih presisi untuk merespons karakteristik unik masing-masing komoditas pangan.

CONCLUSION

Penelitian ini berhasil membuktikan bahwa arsitektur komputasi terdistribusi berbasis *Lakehouse* menggunakan PySpark dan MinIO mampu mengintegrasikan data multivariat berskala besar dari tiga sumber heterogen menjadi satu dataset terpadu yang siap digunakan untuk pemodelan prediktif. Implementasi mekanisme *In-Memory Caching* terbukti meningkatkan efisiensi komputasi secara signifikan dengan memangkas waktu pemrosesan dari 8,48 detik menjadi 3,62 detik. Hasil ini mengonfirmasi relevansi arsitektur terdistribusi dalam mengatasi kendala latensi saat menangani beban data pertanian berskala masif, sekaligus memastikan kesiapan infrastruktur untuk diimplementasikan pada lingkungan produksi nyata secara berkesinambungan.

Dari sisi analitik prediktif, kedua algoritma yang diuji berhasil melampaui target akurasi R^2 sebesar 85% yang ditetapkan di awal penelitian. Model *Decision Tree Regressor* mencatatkan performa terbaik dengan R^2 sebesar 88,65% dan RMSE sebesar 11.319,87, sedikit mengungguli *Random Forest Regressor* yang memperoleh R^2 sebesar 88,24% dan RMSE sebesar 11.522,36. Keunggulan model *Decision Tree* pada dataset ini secara teknis disebabkan oleh dominasi fitur identitas komoditas yang membentuk struktur pemisahan data yang sangat jelas, sehingga mekanisme *ensemble* yang lebih kompleks justru tidak memberikan peningkatan akurasi yang berarti dan hanya menambah beban komputasi.

Analisis *feature importance* mengungkap bahwa seluruh fitur dengan pengaruh tertinggi murni berasal dari representasi variabel jenis komoditas, sementara variabel cuaca dan pergerakan kurs tertutup secara proporsional dan tidak masuk dalam jajaran fitur signifikan. Temuan ini menunjukkan bahwa model saat ini bekerja sangat efektif dalam memprediksi harga

berdasarkan rentang skala identitas komoditas, namun belum optimal dalam mengekstraksi sinyal iklim dan makroekonomi secara spesifik. Oleh karena itu, penelitian selanjutnya sangat disarankan untuk membangun model prediksi yang terpisah secara independen untuk setiap komoditas. Pendekatan tersebut diharapkan mampu mengisolasi pengaruh variabel cuaca dan kurs agar dapat dianalisis dengan lebih bermakna. Pada akhirnya, optimalisasi arsitektur dan pemodelan ini akan menyempurnakan sistem peringatan dini kerawanan pangan, memberikan kontribusi nyata bagi pemangku kebijakan dalam menjaga stabilitas daya beli masyarakat, serta mendukung penuh pencapaian target pembangunan berkelanjutan dalam mengentaskan kelaparan nasional.

REFERENCE

- [1] Murtani, D. Kobi, and Imelda, "Multi-Commodity Food Price Forecasting Ahead of Eid Al-Fitr in Indonesia (2026-2030): A Comparative Study of Machine Learning Algorithms Using Time-Series Data," vol. 6, no. 1, pp. 404–413, 2026, doi: 10.57152/malcom.v6i1.2572.
- [2] K. A. Ammar, A. M. S. Kheir, and I. Manikas, "Agricultural big data and methods and models for food security analysis—a mini-review," Jun. 29, 2022, *PeerJ Inc.* doi: 10.7717/peerj.13674.
- [3] A. Roukh, F. N. Fote, S. A. Mahmoudi, and S. Mahmoudi, "Big data processing architecture for smart farming," in *Procedia Computer Science*, Elsevier B.V., 2020, pp. 78–85. doi: 10.1016/j.procs.2020.10.014.
- [4] T. Yachamaneni, A. Singh Arora, and U. Kotadiya, "International Journal of INTELLIGENT SYSTEMS AND APPLICATIONS IN ENGINEERING Optimizing Big Data Processing Workflows using PySpark and Google Cloud Platform: A Performance Evaluation of Data Locality and Caching Strategies," Jun. 2024. [Online]. Available: www.ijisae.org
- [5] S. M. Okoh, E. O. Ossai, and T. E. Ugah, "Ensemble Machine Learning Application and Feature Importance Detection in Stock Price Prediction," *Asian Journal of Probability and Statistics*, vol. 27, no. 11, pp. 163–178, Nov. 2025, doi: 10.9734/ajpas/2025/v27i11833.

- [6] N. Aditya, I. R. Munthe, and V. Sihombing, "A Comparative Analysis of Machine Learning Algorithms for Predicting Paddy Production," *sinkron*, vol. 8, no. 2, pp. 1200–1207, Apr. 2024, doi: 10.33395/sinkron.v8i2.13666.
- [7] R. F. Ramadhan and W. M. Ashari, "Performance Comparison of Random Forest and Decision Tree Algorithms for Anomaly Detection in Networks," *Journal of Applied Informatics and Computing*, vol. 8, no. 2, pp. 367–375, Nov. 2024, doi: 10.30871/jaic.v8i2.8492.
- [8] I. Rasyid Muchtar, "Comparison of Linear Regression and Random Forest Algorithms for Premium Rice Price Prediction (Case Study: West Java)," *Jurnal Indonesia Sosial Teknologi*, vol. 5, no. 7, p. 3122, 2024, [Online]. Available: <http://jist.publikasiindonesia.id/>
- [9] R. Fadillah, M. Ula, and R. Suwanda, "Machine Learning to Predict Food Prices in Aceh Province Using the Fuzzy Time Series Method Based on Average," *Sinkron*, vol. 9, no. 2, pp. 755–761, Apr. 2025, doi: 10.33395/sinkron.v9i2.14649.
- [10] S. A. Harjanto, S. Sa'adah, and G. S. Wulandari, "Export Commodity Price Forecasting in Indonesia Using Decision Tree, Random Forest, and Long Short-Term Memory," *Jurnal Ilmiah Teknik Elektro Komputer dan Informatika*, vol. 8, no. 4, p. 660, Jan. 2023, doi: 10.26555/jiteki.v8i4.25242.
- [11] F. M. Saragih and W. C. Wibowo, "Analysis of Food Security Index Predictions in Indonesia Using Machine Learning Approach," *Agro Bali*, vol. 8, no. 2, pp. 377–393, 2025, doi: 10.37637/ab.v8i2.2302.